

Federated Learning 관련 Research Question

**Federated Learning에서,
안전하게 데이터 삭제를 할 수 있을까?**

Federated Unlearning 관련 논문

Federated Learning의 한계: 데이터 삭제를 안전하게 할 수 있을까?

1. FedRecovery: Differentially Private Machine Unlearning for Federated Learning Frameworks

- 출판: IEEE TRANSACTIONS ON INFORMATION FORENSICS AND SECURITY, VOL. 18, 2023

2. Guaranteeing Data Privacy in Federated Unlearning With Dynamic User Participation

- 출판: IEEE TRANSACTIONS ON DEPENDABLE AND SECURE COMPUTING, VOL. 22, NO. 3, May/June 2025

3. Model Recovery in Federated Unlearning With Restricted Server Data Resources

- 출판 : IEEE INTERNET OF THINGS JOURNAL, VOL. 12, NO. 11, 1 June 2025

Federated Unlearning 개념의 최초 등장

2021 IEEE/ACM 29th International Symposium on Quality of Service (IWQOS)

FedEraser: Enabling Efficient Client-Level Data Removal from Federated Learning Models

Gaoyang Liu¹, Xiaoqiang Ma¹, Yang Yang², Chen Wang¹, Jiangchuan Liu³

¹Huazhong University of Science and Technology, Wuhan, China

²Hubei University, Wuhan, China

³Simon Fraser University, British Columbia, Canada

¹{liugaoyang, maxiaoqiang, chenwang}@hust.edu.cn, ²yangyang@hubu.edu.cn, ³jcliu@cs.sfu.ca

[Federated Unlearning 개념과 배경]

- 분산 학습 환경에서의 안전한 데이터 삭제

PMLC Lab meeting

2025.08.13 (Wed)

목차

1. Machine Unlearning의 배경
2. Machine Unlearning의 분류
3. Unlearning 알고리즘 설계 시 필수 고려사항
4. Federated Unlearning시 고려해야 할 주요 과제
5. Federated Unlearning 접근 방식
6. 다음주 리뷰할 논문
7. 참고자료

1. Machine Unlearning의 배경

1. Machine Unlearning의 배경

'Right to Be Forgotten' 잊혀질 권리

- 최근 10년 이내 전 세계적으로 관련 법률 제정했거나 제정 중

o GDPR (EU), CCPA (USA), APPI (일본), CPPA (캐나다)

개인 및 조직은 자신의 데이터를 삭제 요청할 권리가 있다 !


→ Privacy 관점에선 😊, ML 모델 관점에선 😭

o 데이터셋에서 타겟 데이터만 삭제

o 이미 학습된 모델에서 타겟 데이터의 영향 제거

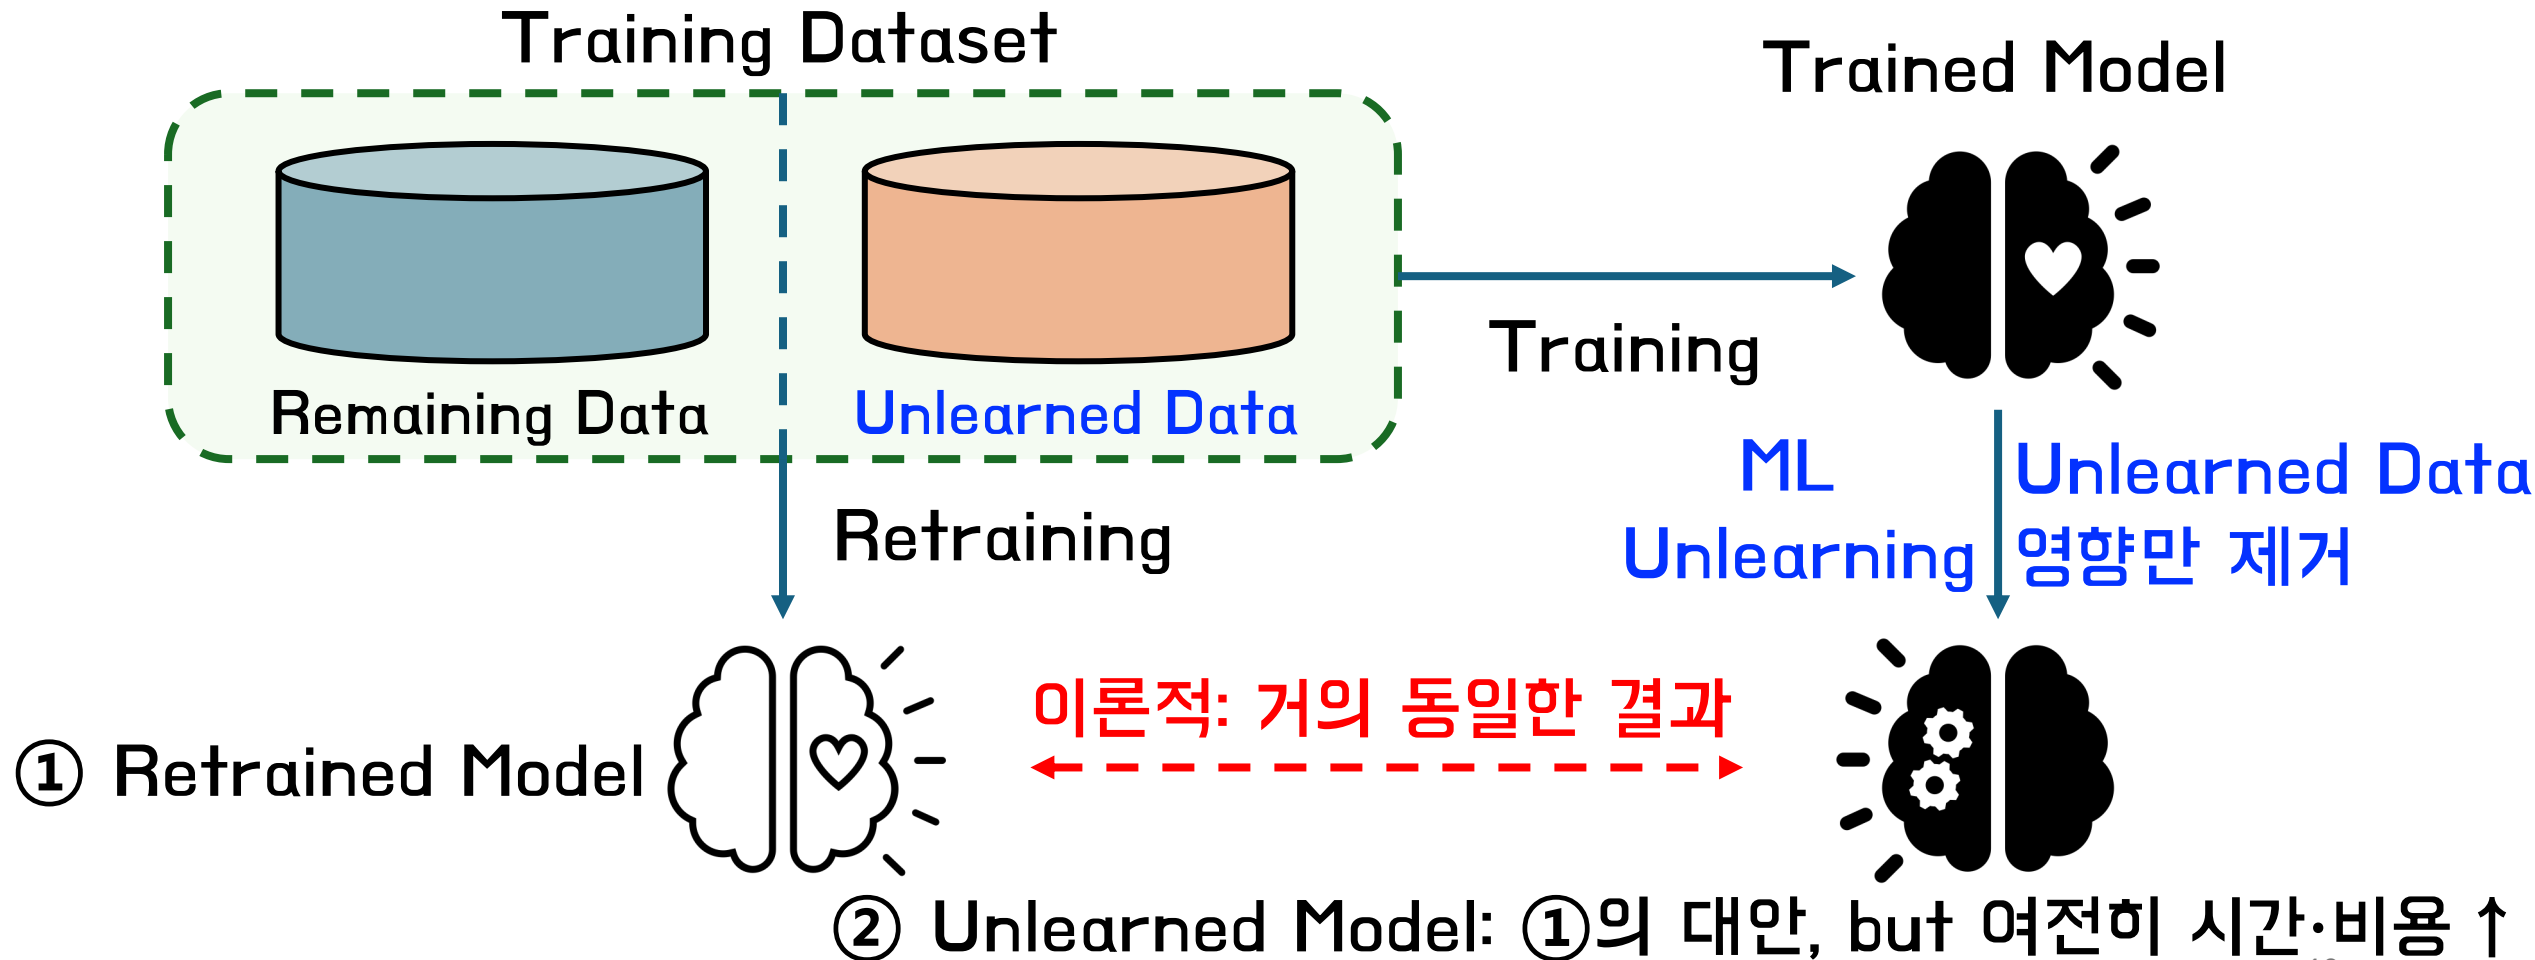
2. Machine Unlearning의 분류

2. Machine Unlearning의 분류 - Naïve Model (1/3)



① Retrained Model: 가장 확실, but 시간·비용 ↑

2. Machine Unlearning 분류의 - Unlearned Model (2/3)



2. Machine Unlearning의 분류 (3/3)

- Strong Unlearning : ① Retrained Model ② Unlearned Model처럼 삭제 요청된 데이터가 학습에 전혀 사용되지 않은 것과 동일한 상태를 목표로 함
 - * 단, 실제 적용 난이도가 높음

[Approximate Machine Unlearning]

- Weak Unlearning : 모델 출력 (예: Accuracy)이 유사하도록 조정하는 것을 목표
 - ① 특정 데이터의 영향을 역으로 적용
 - ② 파라미터 일부 조정 및 성능 저하 최소화를 위한 튜닝
 - * 단, 완전한 데이터 삭제 보장은 불가

3. Unlearning 알고리즘 설계 시 필수 고려사항

3. Unlearning 알고리즘 설계 시 필수 고려사항

- **Consistency**: Unlearned Model과 Retrained Model의 유사성 ↑
- **Accuracy**: 삭제 이후에도 Test Data에서 높은 정확도 유지
- **Verifiability**: Unlearning이 제대로 수행됐는지 검증 가능 필요
- **Efficiency**: 계산·통신 비용 최소화
- **Provable Guarantees**: 수학·이론적으로 삭제의 완전성 보장 필요
- **Privacy Preservation**: 새로운 정보 유출 야기 방지

4. Federated Unlearning시 고려해야 할 주요 과제

4.1 Federated Learning의 특징

[FL 기본 구조 (분산 학습)]

- 중앙서버: 모델 관리 및 최신성 유지
- 클라이언트: 로컬 데이터 관리, 정기적/비정기적인 모델 업데이트 참여


[시나리오]

클라이언트 A

: 제 데이터 삭제 부탁드립니다.

→ 서버, 다른 클라이언트들: ??? 🤔

→ Federated Unlearning 필요성



4.2 Federated Unlearning시 고려해야 할 주요 과제

- **Knowledge Permeation:** 업데이트 영향이 모든 모델에 확산
- **Data Isolation:** 데이터는 클라에서 직접 관리하여 접근 혹은 영향 측정 어려움
- **Who Unlearn:** 어떤 주체(클라·서버)가 실행·관리 할 것인지 선택의 어려움
- **Unlearn What:** 삭제 대상 범위 정하기 어려움 (범위에 따라 난이도·비용 달라짐)
- **Constrained Resources:** 연산량 많은 Unlearning 알고리즘 적용의 한계
- **Participants Heterogeneity:** 클라마다 하드웨어 스펙, 품질 등이 다름
- **Client Dynamics:** 클라가 학습에 참여했다가 빠졌다 하는 동적 환경의 한계

4.2 Federated Unlearning시 고려해야 할 주요 과제

- **Knowledge Permeation**: 업데이트 영향이 모든 모델에 확산
- **Data Isolation**: 데이터는 클라에서 직접 관리하여 접근 혹은 영향 측정 어려움
- **Who Unlearn**: 어떤 주체(클라·서버)가 실행·관리 할 것인지 선택의 어려움
- **Unlearn What**: 삭제 대상 범위 정하기 어려움 (범위에 따라 난이도·비용 달라짐)
- **Constrained Resources**: 연산량 많은 Unlearning 알고리즘 적용의 한계
- **Participants Heterogeneity**: 클라마다 하드웨어 스펙, 품질 등이 다름
- **Client Dynamics**: 클라가 학습에 참여했다가 빠졌다 하는 동적 환경의 한계

4.2 Federated Unlearning시 고려해야 할 주요 과제

- **Knowledge Permeation**: 업데이트 영향이 모든 모델에 확산
- **Data Isolation**: 데이터는 클라에서 직접 관리하여 접근 혹은 영향 측정 어려움
- **Who Unlearn**: 어떤 주체(클라·서버)가 실행·관리 할 것인지 선택의 어려움
- **Unlearn What**: 삭제 대상 범위 정하기 어려움 (범위에 따라 난이도·비용 달라짐)
- **Constrained Resources**: 연산량 많은 Unlearning 알고리즘 적용의 한계
- **Participants Heterogeneity**: 클라마다 하드웨어 스펙, 품질 등이 다름
- **Client Dynamics**: 클라가 학습에 참여했다가 빠졌다 하는 동적 환경의 한계

5. Federated Unlearning 접근 방식

5.1 Federated Unlearning 접근 방식

1. Passive Unlearning : 서버만 Unlearning을 수행

- Server-standalone Unlearning

: 저장된 과거 데이터(gradient, 기여도 정보 등)에 의존

* 단, 서버의 저장 공간 요구량 큼

- Client-aided Unlearning

: 각 라운드에서 수집한 과거 gradient만으로 재구성

2. Active Unlearning : 서버·클라이언트 함께 Unlearning 수행

- 데이터 일부 혹은 클라이언트 자체 삭제

* 단, 클라이언트 참여 부담과 통신량 증가

5.2 Federated Unlearning 지금까지 진행된 연구 한계

1. Proof of Unlearning

- 특정 데이터 영향이 모델에서 제거 됐는지 검증 및 증명 방법 부족

2. 클라이언트 동적 참여 모델링

- FL 환경에서 클라이언트가 지속적으로 참여·이탈하는 데 관련 설계 필요

3. Fairness and Explainability

- Unlearning 모델의 공정성에 미치는 영향 분석

4. Privacy Threat

- Unlearning 과정에서 데이터 및 모델 업데이트 정보가 새로 노출될 가능성 ↑
예) 삭제 요청자의 데이터 패턴이 역으로 유추되는 위험 등

6. 다음주 리뷰할 논문

6. 다음주 리뷰할 논문

4732

IEEE TRANSACTIONS ON INFORMATION FORENSICS AND SECURITY, VOL. 18, 2023

FedRecovery: Differentially Private Machine Unlearning for Federated Learning Frameworks

Lefeng Zhang^{id}, Tianqing Zhu^{id}, Haibin Zhang, Ping Xiong^{id}, and Wanlei Zhou^{id}, *Senior Member, IEEE*

7. 참고 자료

7. 참고 자료

[PEPR '24 – Learning and Unlearning Your Data in Federated Settings \(USENIX\)](#)

